Project Proposal: Reproduction and Extension of Masked Autoencoders for Vision Learning

LAI CHEOK LAM, LIU YIFENG, LUO JIACHENG, LYU SHUJIE
TONG JIAQI, YANG LEYAN, ZHAI SIHAN

1. Research Paper Information

本项目基于以下论文：He, K., Chen, X., Xie, S., Li, Y., Dollár, P., and Girshick, R. (2022). Masked Autoencoders Are Scalable Vision Learners. CVPR 2022 [1].

在传统监督学习框架下，视觉模型的性能高度依赖于大规模人工标注数据，而标注成本高昂且难以扩展；与此同时，已有自监督方法（如对比学习）虽然能够利用无标注数据，但通常依赖复杂的数据增强策略、大规模负样本构造以及高计算资源，限制了其可扩展性和实际应用效率。因此，如何在不依赖人工标注的前提下，以更高的计算效率学习具有强泛化能力的视觉特征，成为视觉表征学习中的核心问题。

为解决上述问题，该论文提出了一种基于 Masked Image Modeling（MIM）的自监督学习框架——Masked Autoencoder（MAE）。其核心思想是通过对输入图像进行高比例随机掩码（如 75%），仅保留少量可见图块输入编码器，并训练模型重建被遮蔽区域，从而迫使模型学习图像的深层结构信息和语义表示。MAE 采用一种非对称编码器–解码器架构：编码器仅处理未被遮蔽的可见图块，从而显著降低计算复杂度；轻量级解码器则结合编码特征与掩码标记重建完整图像。这种设计不仅大幅提高了训练效率，还增强了模型学习全局语义结构的能力。

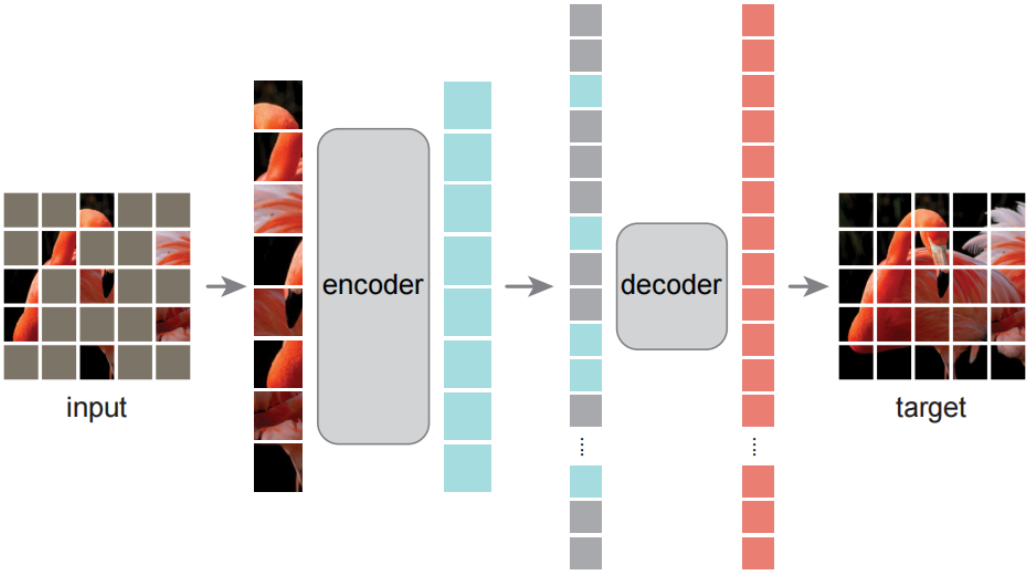

图 1: Masked Autoencoder (MAE) 的非对称编码器-解码器架构示意图。编码器仅处理未被掩码的可见图块，轻量级解码器结合特征与掩码标记重建原图。（图片引自 He et al. [1]）

实验结果表明，MAE 在大规模数据集上能够高效学习通用视觉表征，并在微调后显著提升图像分类、目标检测和语义分割等下游任务性能，验证了其在可扩展视觉自监督学习中的有效性和

优越性。

本项目类型为算法复现与应用扩展（Algorithm Reproduction and Application Extension）。我们将首先“从零构建”复现 MAE 的核心架构与训练流程。在此基础上，我们的扩展工作将聚焦于两个维度：在算法探索层面，突破传统的随机几何掩码范式，探索基于边缘引导（Edge-Guided）和注意力引导（Attention-Guided）的内容感知掩码策略；在实际应用层面，我们将预训练的 MAE 编码器迁移至 Oxford-IIIT Pet 数据集进行语义分割微调。这旨在系统验证模型在面对复杂对象边界和密集预测任务（Dense Prediction）时的局部特征表征能力与泛化性能，从而深入理解 MAE 的作用机制并探索其在特定下游场景的优化空间。

2. Background Reading Plan

为理解 Masked Autoencoders (MAE) 的基本原理与创新点，需要阅读以下相关技术背景：

Masked Autoencoders (MAE)：本项目的基础基准。重点研读其非对称编解码架构及随机掩码实验结论 [1]，作为后续开发边缘引导与注意力引导掩码策略的对照组。

Vision Transformer (ViT)：MAE 的结构核心。通过阅读其原始论文 [2]，理解注意力机制如何将图像块序列化，这对应了本项目中利用注意力权重来引导掩码分布的技术路径。

语义感知的视觉预训练：研究掩码策略从随机向语义感知的演进。参考 BEiT [3] 或类似非均匀掩码的研究，分析为何选取困难样本（如边缘或高注意力区域）进行遮挡能迫使模型学习更深层的结构特征。

语义分割架构与迁移学习：针对 Direction B 的任务需求，阅读经典的分割框架如 Mask R-CNN [4]。了解如何将预训练的 Encoder 与分割后端的 Decoder 结合，以及在 Oxford-IIIT Pet 等精细化数据集上的微调技巧。

3. 复现与扩展方案

3.1. 复现方案

为了证明对模型架构的实质性掌握，我们将采用“从零构建 (Implementation from scratch)”的工程策略，明确不直接调用现成的高级模型库（如 timm 或 transformers 中的高级 API）。具体实现步骤如下：

底层模块搭建：完全基于 PyTorch 框架，利用基础的线性层与注意力机制，手动搭建包含 Multi-head Self-Attention 的 ViT 基础模块 (Block)。

核心逻辑实现：自主编写主导数据流向的 random_masking 函数，以及实现 PatchEmbedding。

张量维度优化：在前向传播 (Forward Pass) 的过程中，引入 einops 库来处理所有复杂的张量重塑操作，这不仅能提升代码的可读性，也能确保架构的模块化解耦（如分离 Encoder 和 Decoder）。

增加可视化探针：在网络内部关键节点注册 Hooks，用于记录和导出关键信息，如中间层的注意力映射图 (Attention Maps)，以增强复现模型的可解释性。

3.2. 扩展研究方案

在成功搭建并验证基线模型后，我们将在算力预算范围内，从掩码机制和下游应用两个维度展开扩展研究：

Direction A: 内容感知的掩码策略探索

原论文评估了随机掩码 (Random)、块状掩码 (Block) 以及网格掩码 (Grid) 三种策略，这些方法本质上均属于“非语义感知 (Content-agnostic)”的盲目几何遮挡。为了进一步探究模型对复杂结构的重建极限与高级语义推理能力，我们将突破传统的空间遮挡范式，探索两种基于“困难样本挖掘 (Hard Example Mining)”理念的掩码机制：边缘引导掩码 (Edge-Guided Masking) 和注意力引导掩码 (Attention-Guided Masking)。

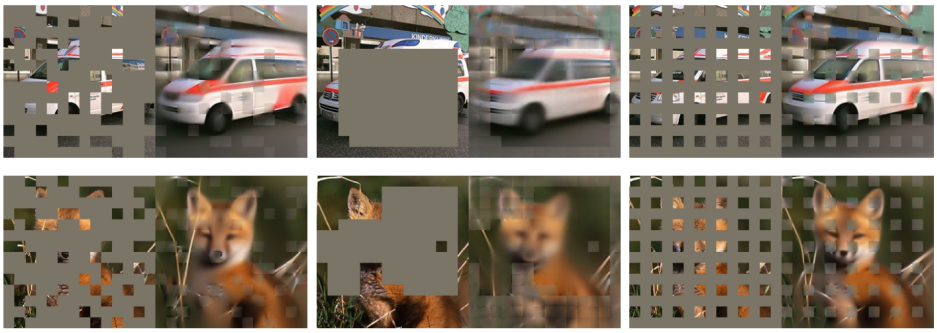

random 75%　　block 50%　　grid 75%

图 2: 不同掩码策略的可视化对比。原论文探讨了随机掩码（Random）、网格掩码（Grid）及块状掩码（Block）等不同遮挡方式。本项目将在此基础上进一步探索内容感知（Content-aware）的掩码机制。（图片引自 He et al. [1]）

Direction B: 下游语义分割任务

为了验证预训练特征的有效性，我们将把 MAE 的 Encoder 迁移到 Oxford-IIIT Pet 数据集上进行语义分割微调。该数据集包含复杂的宠物轮廓和毛发边缘，适合检验 MAE 学习到的像素级局部特征。

4. 评估方案

受限于计算资源，我们预期模型难以达到原论文在全量数据下训练 800 个 Epoch 的绝对精度。因此，本项目的评估体系将重点放在基线对比与相对性能增益上。

图 3: 本项目在初步复现阶段的预训练定性结果（基于 ImageNet-Mini，训练 100 Epochs）。初步结果表明，模型已具备一定的局部结构推断与色彩恢复能力。

4.1. 定性评估

重建能力可视化：直观对比验证集上的“原始输入图像”、“掩码图像”以及“模型重建图像”。重点观察模型在不同掩码策略下，能否合理推断出缺失部位的基本轮廓和色彩。

分割结果对比：在下游任务中，输出 Oxford-IIIT Pet 的预测分割掩码，观察模型对复杂物体边缘（如动物毛发、躯干边界）的划分是否清晰。

4.2. 定量评估

预训练阶段 (Pre-training)：持续监控并记录掩码区域内重建像素与真实像素之间的均方误差 (MSE Loss)，以此作为模型信息压缩与恢复能力的量化指标。

下游微调阶段 (Fine-tuning for Segmentation)：在 Oxford-IIIT Pet 数据集上评估平均交并比 (mIoU)。我们将引入一个“随机初始化的 ViT-Base 模型 (Trained from scratch)”作为严格基线。通过对比“随机初始化模型”与“MAE 预训练模型”在相同微调条件下的 mIoU 差异，来量化证明即便在小规模算力下，MAE 预训练依然能为密集预测任务 (Dense Prediction) 带来显著的特征迁移优势。

5. Division of Work

项目由 7 名成员完成，初步分工如下：

- 论文阅读与文献调研：所有人
- proposal 撰写：LYU SHUJIE, TONG JIAQI, YANG LEYAN
- 模型复现：2 人
- 拓展方向 A：2 人
- 扩展方向 B：2 人

所有成员将共同参与问题讨论、调试和最终报告整理。

参考文献

[1] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked Autoencoders Are Scalable Vision Learners. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022.

[2] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, et al. An Image Is Worth 16x16 Words: Transformers for Image Recognition at Scale. In *International Conference on Learning Representations (ICLR)*, 2021.

[3] Hangbo Bao, Li Dong, Songhao Piao, and Furu Wei. BEiT: BERT Pre-training of Image Transformers. In *International Conference on Learning Representations (ICLR)*, 2022.

[4] Kaiming He, Georgia Gkioxari, Piotr Dollár, and Ross Girshick. Mask R-CNN. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2017.